Laya 아키텍처를 이용한 로그 연관 위협탐지와 저지연 자동 대응 시스템 설계

Design of a Low Latency Threat Detection and Response System with Laya

이벤트 수집부터 정책 집행까지의 시스템 설계와 공개 네트워크 흐름 실증 | 2026 년 10 월 7 일

초록

네트워크 위협의 초기 대응은 여러 로그의 문맥을 해석하는 능력과 짧은 판정 지연을 동시에 요구한다. 생성형 대규모 언어모델을 이용해 위협 설명까지 동기적으로 생성하면 대응 결정이 설명 완료를 기다리는 구조가 된다. 본 연구는 언어로 기술된 상태와 판정 기준을 입력받되 텍스트 생성 없이 선택지 점수를 반환하는 Laya 를 빠른 위협 판정 경로에 배치하고, 별도 생성형 언어모델이 증거 설명을 비동기적으로 담당하는 구조를 제안한다. 설계는 관측 시각을 보존하는 이벤트 수집, 주체별 sliding window, 위협·위험 수준·조치 후보의 선택지 판정, 정책 검증과 만료 기반 복구, 비동기 설명으로 구성한다. 단일 인코딩에서 여러 선택지 그룹을 점수화하는 확장 모델과 단계별 학습 방법도 제안한다. 핵심 관점은 언어 사전학습을 활용하는 판정 인터페이스를 유지하면서 응답 경로에서 순차적인 설명 생성을 제거하는 데 있다.

실증 평가에서는 NF-UNSW-NB15-v2 의 2,390,275 개 흐름을 사용해 FlowTransformer 의 여덟 비교 설정과 Laya 를 평가했다. Laya 의 완료된 두 학습 반복은 평균 F1 93.90%, 공격 탐지율 99.948%, 오탐률 0.946%를 보였다. 같은 RTX 4090 에서 입력 준비를 포함한 단일 요청 지연 p95 는 80.03ms 와 76.37ms 로, 사전에 정한 추론 경로의 200ms 목표를 충족했다. 그러나 최상 비교군 Encoder Projection 은 F1 94.49%, 오탐률 0.832%, p95 16.22ms 로 더 나은 F1·오탐·지연을 보였다. 또한 실제 호스트·시간 관계에 의존하는 연관 탐지, 미학습 공격, 대응 방책 선택 및 차단 효과는 평가하지 않았다. 결과는 Laya 가 저지연 언어 기반 판정 계층의 실현 가능성을 갖는다는 근거를 제공하며, 언어모델의 장점을 실시간 대응에 연결하려는 설계적 진전의 방향을 지지한다. 다만 언어 이해 능력의 보존과 기존 탐지기를 능가하는 종합 성능은 별도의 검증 과제다.

주제어 Laya 비생성형 의사결정 모델 네트워크 위협탐지 로그 연관 분석 저지연 추론 자동 대응

1 서론

보안 운영에서 단일 연결의 패킷 수나 전송량만으로는 정상과 공격을 구분하기 어려운 경우가 있다. 같은 주체의 DNS 조회, 반복 연결, 대상 변경, 전송량 증가를 시간과 관계에 따라 결합해야 위협 가능성을 판단할 수 있다. 언어모델은 서로 다른 로그 형식과 자연어로 기술된 정책을 한 입력 안에서 다룰 수 있어 이러한 연관 분석의 후보가 된다. 그러나 설명문 생성, 다단계 추론, 원격 호출을 모두 초기 차단 이전에 수행하는 구성에서는 각 단계의 지연이 대응 경로에 누적된다. 이 문제는 모든 LLM 이 항상 느리다는 일반 명제가 아니라, 설명 생성까지 기다리는 시스템 구성의 문제로 정의한다.

Jev 와 Laya 는 상태와 질문을 받아 정해진 선택지 또는 점수의 분포를 반환하는 접근을 제시한다[3–5]. 이 접근은 자연어 입력과 유연한 판정 기준을 활용하면서 출력 생성을 제한하므로, 프로그램이 빠른 결정을 직접 소비할 수 있는 가능성을 제공한다. 본 연구는 이 방향을 네트워크 방어에 적용한다. 빠른 모델은 위협 여부와 대응 후보를 판정하고, 설명이 필요한 경우 별도 LLM 이 원본 증거와 판정 기록을 토대로 상세 분석을 수행한다. 초기 대응이 완료된 뒤 설명을 제공할 수 있으므로, 설명의 길이와 초기 판정 지연을 분리할 수 있다.

본 연구는 관계가 보존된 입력, Laya 기반 판정, 대응·복구 절차를 설계하고, 공개 흐름 데이터의 정확도와 추론 지연을 평가한다. 유사한 보안 의사결정 계층이 논의됐으므로[6], 기여는 방어용 시스템 설계와 확인 가능한 실측에 둔다. 설계 확장과 실험에 사용한 이진 모델은 구분한다.

2 관련 연구와 연구 질문

2 1 흐름 Transformer 와 언어 사전학습

FlowTransformer 는 입력 인코딩, Transformer, 분류 헤드를 교체하며 네트워크 흐름 분류를 평가하는 프레임워크다[1,11]. 여러 흐름의 표현을 함께 처리하므로 수치 패턴의 관계를 학습할 수 있지만, 모델에 여러 행을 넣었다는 사실만으로 시간·호스트·공격 단계의 의미적 연관을 활용했다고 볼 수는 없다. 본 연구에서는 arXiv v1 의 Table III UNSW-NB15 설정을 기준으로 네 계열의 각 두 설정을 재실행했다. 논문에 등장하는 GPT·BERT 는 저자 코드의 구조를 처음부터 학습한 비교군이며, 상용 GPT 서비스나 사전학습 Qwen 과 다르다.

ModernBERT 는 분류와 검색을 위한 양방향 언어 인코더로, 효율적인 추론과 긴 문맥 처리를 고려한 구조를 제시한다[2]. Laya 는 이러한 언어 사전학습 인코더와 판정 헤드를 결합한다[3]. 따라서 Laya 와 작은 Encoder 의 차이는 Encoder 사용 여부보다 사전학습, 입력 표현, 모델 용량 및 학습 목적에 있다. 언어 사전학습 가중치를 사용한다는 사실은 장점의 활용 경로를 제공하지만, 보안 파인튜닝 뒤 의미 이해나 미학습 공격 일반화가 유지됐다는 실증 결과를 대신하지 않는다.

2 2 Jev 와 Laya 의 의사결정 인터페이스

TypeSafe 의 Jev 소개 자료는 비생성형 구조화 결정과 낮은 응답 지연을 지향한다[4]. 개발사의 특정 업무 벤치마크에서 보고한 가속 배율은 본 연구의 네트워크 탐지 결과와 직접 결합하지 않는다. Jev 와 Laya 는 유사한 인터페이스 방향을 공유하지만, Jev 의 내부 구조가 Laya 와 동일하다고 가정하지 않는다. 또한 형식에 맞는 출력을 반환하는 성질과 판정 내용이 올바른 성질은 구분해야 한다.

Deußer 등의 사전공개 연구는 Jev 를 37 개 일반 언어 과제에서 평가했다[5]. 일부 분류·추론 과제에서 높은 성능을 보고했지만, 이진 판정의 임계값과 과제별 보정 문제도 지적했다. 해당 연구의 평균 클라이언트 지연은 동시 요청 32 개 조건에서 0.36 초이며 네트워크 시간이 포함됐다. 이 값은 본 연구의 로컬 Laya p95 와 측정 경계가 달라 속도 순위 산정에 사용하지 않는다. DiGiuseppe 와 Denney 의 사회과학 과제 연구도 정확도·보정·비용의 이점이 과제와 비교 조건에 따라 달라짐을 보고했다[7]. 이들 연구는 의사결정 모델의 언어 활용 가능성을 뒷받침하지만 네트워크 연관 탐지 능력을 입증한 자료는 아니다.

Barbosa 는 Jev·Laya 를 LLM 기반 침투시험의 의사결정 계층에 배치하는 구성을 논의했다[6]. Jev 유무를 각각 한 번 실행한 사례 연구이며 Laya 의 보안 성능을 직접 비교하지 않았다는 한계를 명시했다. 본 연구는 이 흐름을 방어용 네트워크 탐지로 확장하되, 아키텍처의 타당성과 실험으로 확인한 성능을 분리한다.

2 3 검증할 주장과 현재 근거

표 1 연구 질문과 본 연구의 증거 범위

연구 질문	현재 상태	판단 근거
Laya 판정 경로가 200ms 이내인가	측정 완료	두 체크포인트 p95 76.37–80.03ms
기존 흐름 탐지기보다 우수한가	종합 우위 미입증	F1·오탐·지연 불리, 탐지율 소폭 증가
언어 이해와 연관 탐지 장점이 유지되는가	후속 검증 필요	문맥 대조·언어 능력 평가 없음
생성형 LLM 보다 빠르게 같은 위협을 찾는가	직접 비교 없음	동일 입력의 생성형 LLM 측정 없음
자동 대응이 공격 확산을 줄이는가	제안 단계	정책 실행 및 피해 억제 실험 없음

3 로그 연관 위협탐지와 자동 대응 시스템 설계

시스템의 목표는 여러 네트워크 사건의 관계를 입력으로 받아 초기 대응 결정을 신속하게 반환하는 것이다. 한 패킷마다 언어모델을 실행하는 구조가 아니라, 누적 사건의 의미를 판정한 결과로 데이터 경로의 규칙을 갱신하는 구조다. 이 절은 구현을 위한 제안 설계이며, 제 5 절과 제 6 절의 실험은 이 가운데 원래 Laya 의 이진 흐름 판정과 로컬 추론 지연만 검증했다.

3 1 문제 정의와 처리 경계

사건 e 는 센서 식별자, 사건 식별자, 사건 시각, 수집 시각, 통신 주체와 대상, 프로토콜 특성 및 관측 품질로 표현한다. 주체 u 에 대해 시각 t 에 실제 도착한 사건으로 window W(u,t)를 만들고, 모델은 위협 점수, 조건부 위험 수준, 대응 후보 분포를 계산한다. 정책 제어기는 현재 장비 상태와 자산 식별 정보를 결합해 실행 가능성을 결정한다. 탐지 확신도와 위협의 피해 규모는 별도 변수로 취급한다.

$$W(u,t) = \{e : t - H < event_{time}(e) \le t, arrival_{time}(e) \le t, related(e,u)\}$$

H 는 과거 관측 범위다. 실제 입력은 사건 수와 토큰 예산으로 한 번 더 제한한다. 사건 시각은 센서의 보정된 시계를 사용하고, 처리 경과 시간은 해당 프로세스의 단조 시계로 계측한다.

W 는 과거를 돌아보는 sliding window 이므로 10 초 범위를 사용한다고 매번 10 초가 끝나기를 기다리지는 않는다. 새 사건이 도착하면 이미 보관한 문맥을 갱신해 판정한다. 다만 공격을 구별하는 후속 증거가 아직 발생하지 않았다면 어떤 모델도 그 증거를 미리 사용할 수 없다. 본 연구는 이 관측 대기와 모델 계산 지연을 별도로 측정하도록 설계한다.

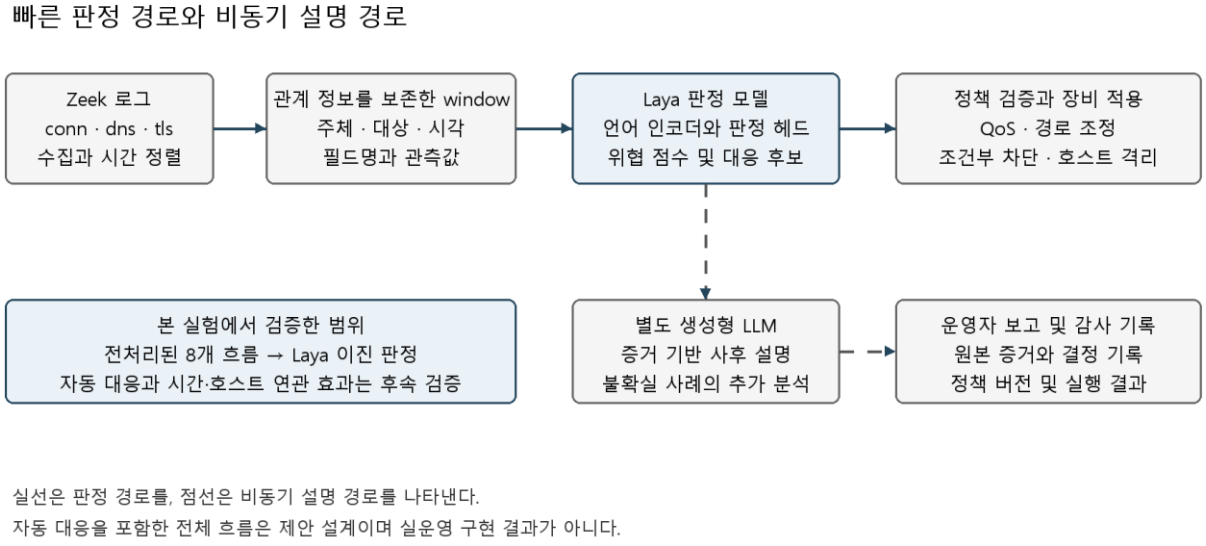


그림 1 빠른 위협 판정과 비동기 설명을 분리한 전체 제안 구조

수집·판정 서비스는 전달 및 분석을 담당하고, 정책 서비스만 조치 권한을 가진다. 원본 증거와 결정 기록은 감사 저장소에 남긴다. 생성형 LLM 은 감사 자료를 읽어 설명을 작성하며 빠른 경로의 필수 의존성이 아니다. 그림의 자동 대응 전체를 구현·실측했다는 뜻은 아니며, 실제 검증 단위는 전처리된 여덟 흐름의 이진 판정이다.

3 2 조기 관측과 이벤트 수집

Zeek 의 uid 는 연결 관련 로그를 연결하는 근거이며 ts 는 연결 시작 시각일 수 있다[9]. 이 값만으로 로그가 언제 판정기에 도착했는지 알 수는 없다. 따라서 원본 사건 시각, 센서가 내보낸 시각, 판정 서비스 수신 시각을 모두 기록한다. 연결이 끝난 뒤 확정되는 최종 전송량과 duration 을 조기 판정의 입력으로 소급 제공하지 않는다. 학습용 재생도 실제 도착 순서와 필드 가용 시점을 따라야 한다.

조기 탐지를 위해서는 연결 시작과 진행 중 통계, DNS·TLS 관측을 필요한 시점에 내보내는 수집 경로가 필요하다. Zeek 는 new_connection 과 진행 중 connection_status_update 같은 이벤트를 제공한다[12]. 제안 수집기는 필요한 필드의 부분 스냅샷을 전달하고, finalized 여부와 관측 구간을 함께 표시한다. 전송·flush 주기와 연결 상태 갱신 주기는 실제 설치 버전에서 확인해야 하며, 이 이벤트들이 별도 설정 없이 모든 로그를 즉시 내보낸다고 가정하지 않는다.

연동 대상 Security Switch 의 현재 코드에는 활성 로그를 1 초 간격으로 읽는 수집 루프가 있다[14]. 이 경로를 그대로 사용하면 모델 계산이 80ms 여도 수집 대기 때문에 200ms 전체 대응을 보장할 수 없다. 따라서 빠른 판정용 스트림은 센서 인접 전달 경로로 설계하고, 기존 SQLite·Syslog·조회 경로는 보존과 사후 분석에 이용한다. 두 경로에는 동일한 사건 식별자를 부여해 중복 처리와 증거 불일치를 방지한다. 제안한 별도 수집 경로의 구현과 전체 지연 측정은 후속 검증 과제다.

수집기는 tenant, sensor, sensor 실행 구간, uid 및 원본 레코드 식별자로 중복을 제거한다. 서로 다른 센서의 uid 나 NAT 전후 주소를 같은 연결로 임의 병합하지 않는다. 센서 간 상관키를 사용하더라도 관측 위치·주소 변환·시간 오차를 검증하고 원래 출처를 유지한다. 센서가 볼 수 없는 트래픽과 암호화된 페이로드는 관측 누락으로 남긴다.

3 3 주체별 window 와 관계 표현

연관 저장소는 주체별 최근 사건과 연결별 부분 상태를 관리한다. 같은 uid 의 DNS·TLS·연결 기록은 직접 연결하고, 서로 다른 연결은 자산 식별자, 대상 서비스, 시간차를 근거로 묶는다. 주체 window 외에 주체와 대상 쌍 및 대상 서비스별 집계를 보조 문맥으로 두어 한 주체의 반복 시도와 여러 주체가 한 서비스에 집중하는 경우를 구분한다. 관계를 제공해도 모델이 이를 올바르게 활용하는지는 별도 대조 실험으로 검증한다.

모델 입력에서는 주소를 일관된 익명 주체 토큰으로 변환하되 같은 window 안의 동일성과 연결 관계는 유지한다. 원본 IP·MAC·포트와 토큰의 매핑은 권한이 있는 대상 해석기만 보관한다. DHCP 임대, NAT, 공유 주소, VLAN, 센서 범위를 고려해 한 IP 가 항상 한 호스트라는 가정을 피한다. 학습·평가 간 토큰을 재매핑해 특정 주소나 호스트 이름의 암기로 정답을 찾는 경로를 줄인다.

표 2 window 와 입력 예산의 초기 설계값

항목	초기 설계안	선택 이유와 검증 조건
최근 원본 문맥	과거 10 초 중 최대 32 사건	짧은 연속 행동을 보존하며 1·10·60 초를 비교
장기 보조 문맥	과거 300 초의 결정적 집계	느린 반복을 보완하며 원본 문맥과 기여를 분리
총 토큰 상한	정책·선택지 포함 4,096	질문 공간을 먼저 확보하며 2,048 과 비교
판정 트리거	새 사건 또는 의미 있는 상태 갱신	window 종료를 기다리지 않고 중복 갱신을 병합
동일 주체의 동시 작업	진행 중 1 개와 최신 대기 1 개	이전 결과의 순서 역전과 무제한 큐 누적 방지
조치 후보 갱신	정책 및 장비 기능 revision 별	구형 후보·권한·기능 상태로 실행하는 것을 방지

표의 수치는 구현 가정이며 최적값이나 실측 성능이 아니다. 작은 문맥에서 시작해 관계 보존과 계산 비용을 함께 검증하려는 설정이다. 기존 속도 실험은 최대 약 2,080 토큰의 다른 입력이므로 이 설계값에 지연 결과를 그대로 적용하지 않는다.

토큰 예산을 넘으면 최근 사건, 대상 사건과 직접 연결된 증거, 서로 다른 사건 종류를 우선 보존하는 결정적 선택기를 사용한다. 나머지는 횟수·전송량·대상 수처럼 재계산 가능한 집계로 압축하고, 제외 수와 범위를 표시한다. 생성형 요약을 빠른 경로에 추가하지 않는다. 조용한 truncation 은 거부하며 필요한

증거가 빠졌으면 판정을 보류한다. 조치로 발생한 연결 실패는 intervention 표식을 붙여 모델이 자기 차단 결과를 새로운 공격 증거로 증폭하지 않도록 한다.

늦게 도착한 사건은 새 window revision 에 반영한다. 이미 실행된 결정을 덮어쓰거나 미래 사건을 과거 입력에 삽입하지 않는다. 오래된 요청은 감사를 위해 남기되 새 조치의 근거로 사용하지 않는다. 중첩 window 여러 개의 높은 점수는 독립 증거 여러 개로 세지 않으며 원본 사건 ID 를 기준으로 중복을 제거한다.

3 4 입력과 출력의 계약

직렬화 형식은 버전을 갖는 구조화 레코드와 짧은 자연어 판정 기준으로 구성한다. 모델에 전달하는 필드명·단위·결측 표기를 고정하고 로그 문자열은 데이터 구역에 넣는다. 로그 안의 명령형 문장이 정책이나 선택지를 바꾸지 못하도록 정책은 별도 신뢰 경로에서 공급한다. 이러한 구분만으로 프롬프트 주입 내성이 입증되지는 않으므로 악의적 도메인·URL·메시지를 포함한 평가가 필요하다.

표 3 판정 요청과 결과의 주요 필드

객체	필드	의미와 소유자
요청 식별	window_id, revision, cutoff_time	수집기가 정한 관측 경계와 동일 요청의 식별
관측 문맥	entity_refs, events, aggregates	시각·관계·단위가 보존된 사건과 결정적 집계
품질 정보	missing, dropped, stale, intervention	결측·제외·노후·기존 조치 영향을 명시
신뢰 정책	policy_version, capability_version	정책 서비스가 제공하는 기준과 사용 가능한 기능
모델 점수	threat_score, severity_scores, action_scores	모델의 분포이며 보정 버전을 함께 기록
판정 상태	decision_status, threat, action_id	decided 일 때 true/false, 보류 시 threat 는 null
실행 바인딩	target_ref, profile_id, valid_until	정책 계층이 검증한 대상·사전 정의 프로필·유효기한
추적 정보	model_version, evidence_ids, decision_id	원본 증거·모델·결정·실행 작업의 연결

true/false 만 반환하면 입력 손실이나 시간 초과를 정상으로 오인할 수 있으므로 판정 상태를 별도로 둔다. 입력 검증·모델 계산·보정이 완료된 경우에만 threat 를 채우고, 불충분하거나 유효기간이 지난 결과는 deferred 또는 expired 로 반환한다. 대응 후보와 실제 적용 결과도 분리한다. 모델이 선택한 action_id 가 있더라도 정책 검증과 실행 확인 전에는 차단 완료로 기록하지 않는다.

3 5 Laya 판정 모델과 다중 선택지 확장

실험에 사용한 영어 Laya 는 ModernBERT-large 기반 언어 인코더, 두 층의 판정 Transformer, 선택지 마커 점수기 및 act/escalate 헤드를 포함한다[3]. 전체 파라미터는 421,293,827 개다. 원본 구조는 상태와 한 질문을 토큰열로 인코딩하고 선택지 마커 위치의 표현에서 점수를 산출한다. 이번 학습은 false/true 하나만 판정했으며 일반 대응 조치의 분포를 학습하지 않았다.

$$p(attack \mid W, q) = exp(s_{true}) \,/\, (exp(s_{false}) + exp(s_{true}))$$

실험의 결정 규칙은 p > 0.5 다. 이 점수를 배포 환경에서 이미 보정된 위협 확률로 해석하지 않는다.

전체 설계에는 위협 여부, 위험 수준, 대응 후보의 세 선택지 그룹을 둔다. 위협 여부는 정상·위협, 위험 수준은 낮음·중간·높음, 대응 후보는 표 4 의 여섯 기능이다. 위험 수준은 위협이 존재한다는 조건 아래

예상 피해와 자산 중요도를 반영하도록 정의하며 위협일 확률 자체와 구별한다. 정책 계층은 판단 보류와 목표 미확인을 별도 상태로 처리한다.

정상으로 판정한 경우 위험 수준은 적용하지 않고 관측 유지를 기본 결과로 둔다. 위험 수준 손실은 공격 정답과 수준 정답이 함께 있는 표본에만 적용하며, 대응 손실은 허용 조치 정답이 있는 표본에만 적용한다. 모델 결과가 정상인데 강한 조치를 제안하는 등 그룹 간 모순이 생기면 정책 계층이 실행을 거부하고 불일치 지표에 기록한다.

단일 인코딩을 공유하려면 기존 입력 빌더와 forward 를 확장해야 한다. 공통 문맥과 세 질문, 그룹별 선택지 마커를 한 토큰열에 배치하고, 인코더와 판정 Transformer 를 한 번 통과한 뒤 그룹별 softmax 를 적용하는 구조를 제안한다. 원래 Laya 의 한 질문에 대한 softmax 를 모든 선택지에 그대로 적용하면 서로 다른 질문의 확률이 경쟁하므로 이 확장이 필요하다. qtype 은 choice 로 통일하고 질문별 의미는 텍스트와 마커 그룹으로 명시한다. 원래 act/escalate 헤드를 라우터 기능 헤드로 재해석하지 않는다.

$$p_g = softmax(s_g / T_g)$$

g 는 위협·위험 수준·조치의 그룹, s 는 해당 그룹의 마커 점수, T 는 검증 구간에서 맞춘 양의 보정 온도다. 그룹별 마커 수와 손실 마스크를 입력 검증에서 확인한다.

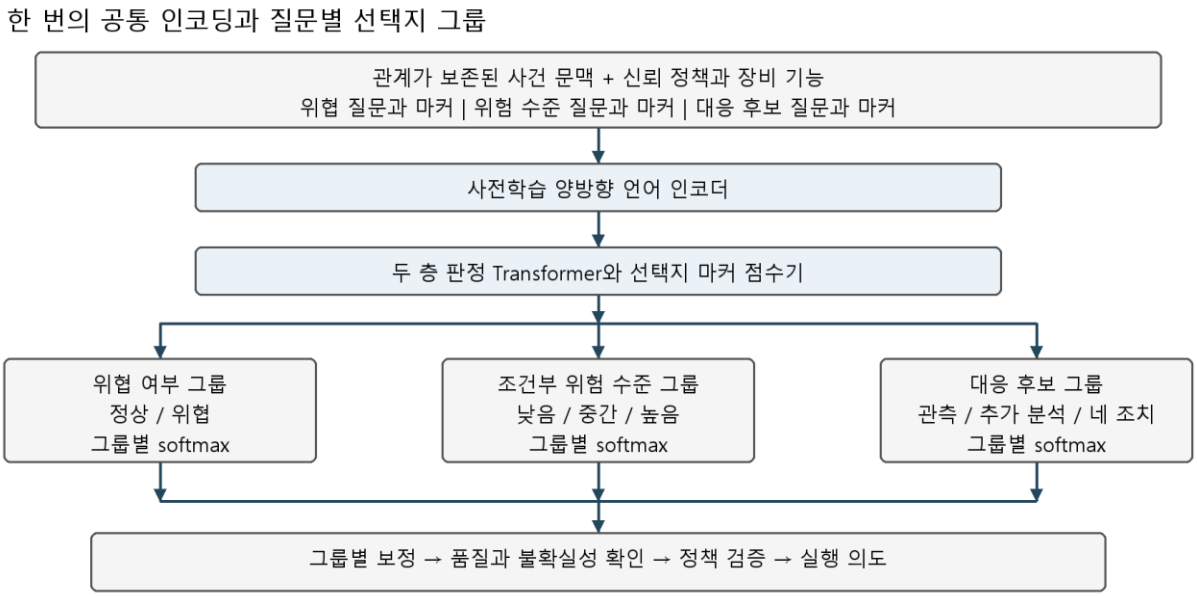


그림 2 공통 언어 인코딩과 그룹별 선택지 점수화를 사용하는 확장 설계

그림 2 의 확장은 아직 구현·학습·계측하지 않았다. 별도의 세 요청을 batch 로 실행하는 것과 한 토큰열의 계산을 공유하는 것은 다르며, 세 질문 때문에 토큰 수와 상호 간섭이 늘 수 있다. 따라서 기존 이진 모델, 공통 인코딩 확장, 질문별 별도 호출을 같은 입력과 정확도 조건에서 비교한다. 속도나 언어 능력의 보존은 이 비교 뒤에 판단한다.

3 6 대응 기능과 정책 결정

모델은 허용된 기능의 식별자를 순위화하고 정책 제어기는 대상·기능·비용·증거를 확인한다. QoS 비율, 경로, 패킷 조건, 적용 기간을 자유 문자열로 생성하게 하지 않고 검증된 프로필을 선택하게 한다. 서로 다른 조치가 동시에 필요할 때는 상태를 다시 확인한 후 후속 작업을 계획한다. 첫 설계는 한 결정에 한 조치를 실행해 충돌과 검증 범위를 제한한다.

표 4 제안하는 Security Router 기능 목록

기능 식별자	효과와 적용 대상	필수 검증과 복구
OBSERVE	현재 정책을 유지하고 관측	정상 확정과 자료 부족을 별도 기록
DEFER_ANALYSIS	추가 증거 수집과 비동기 분석 요청	시간 초과·자료 부족을 정상으로 분류하지 않음
QOS_PROFILE	특정 연결·클래스·주체의 속도 제한	지원 단위·최저 서비스 수준·기한·해제 확인
ROUTE_PROFILE	사전 정의된 검사·격리 경로로 전환	대체 경로 상태·루프·세션 영향·원경로 복구
DROP_SELECTOR	허용된 헤더 조건과 일치하는 패킷만 차단	범위 최소화·양방향·기존 연결·규칙 만료 검증
ISOLATE_HOST	확인된 호스트의 연결 범위를 제한	주소·MAC·VLAN·포트 대응 및 보호 대상 확인

일부 패킷 차단은 미리 검증된 헤더 조건에 맞는 집합을 데이터 경로에서 차단한다는 뜻이다. Laya 가 모든 패킷을 읽거나 암호화된 내용에서 악성 바이트를 식별한다는 뜻이 아니다. 호스트 전체 연결 제한도 공유 NAT 주소나 trunk 포트를 단순 차단하는 방식으로 대체하지 않는다. 대상이 모호하면 조치를 보류한다. 위험 수준이 높다고 언제나 호스트 격리를 선택하는 고정 대응표도 사용하지 않는다.

정책 결정은 먼저 현재 지원 기능과 대상 범위로 실행 가능한 후보를 걸러낸다. 이어 정상 서비스 손실, 예상 공격 피해, 복구 비용을 반영해 후보를 선택한다. 비용을 데이터로 추정할 수 있을 때에는 보정된 위협 확률에 따른 기대 비용 최소화를 사용할 수 있다. 비용 근거가 부족한 초기 단계에서는 사전 검증된 규칙과 모델 후보 순위를 결합하고 이를 최적 정책이라고 부르지 않는다. 허용 목록으로 후보를 줄인 뒤 점수를 재정규화하는 것만으로 보정이 보장되지도 않는다.

낮은 점수 구간은 관측 유지, 높은 점수 구간은 조치 검토, 중간 구간은 추가 분석으로 나누되 임계값을 독립 검증 자료에서 정한다. 강한 조치에는 별도의 높은 증거·대상 확정 기준을 적용한다. 적용과 해제 기준을 다르게 두고 최소 유지 시간 및 cooldown 을 사용해 반복적인 QoS·경로 변경을 억제한다. 기간과 임계값은 운영 가정 및 실험 결과로 기록하며, 현재 논문에는 검증되지 않은 고정 차단 임계값을 제시하지 않는다.

3 7 실행 계약과 만료 복구

판정 서비스가 정책 제어기에 보내는 객체는 실행 의도다. 실행 의도에는 결정 ID, 증거 참조, 대상 참조, 기능·프로필, 정책 버전, 기대 장비 revision 및 유효기간을 포함한다. 장비 설정 명령은 제어기가 자신의 검증된 코드로 생성한다. 모델 서비스에는 root 권한이나 장비 셸 실행 권한을 주지 않는다. 관리 경로와 보호 자산에 대한 예외는 자연어 입력이 아니라 제어기의 강제 제약으로 검사한다.

작업 상태는 proposed → validated → applying → active → reverting → expired 로 추적한다. 검증 실패는 rejected, 적용 실패는 failed, 복구 실패는 rollback_failed 로 분리한다. active 는 API 접수만으로 부여하지 않고 장비 readback 과 필요한 데이터 경로 확인 뒤 부여한다. 구성 확인과 실제 공격 억제는 다시 구분한다. 규칙 카운터와 격리된 검증 패킷 등으로 해당 경로의 집행 여부를 확인하고, 운영 트래픽의 성능 영향도 기록한다.

동일 decision_id 의 재전송은 동일 작업을 반환해야 하며 다른 내용으로 재사용하면 거부한다. revision 충돌은 최신 상태에서 정책을 다시 검증하고, 시간이 지난 모델 결정을 그대로 재적용하지 않는다. 결과가 늦게 돌아오면 현재 주체 window 와 비교해 더 최근 결정의 효과를 덮어쓰지 않도록 한다. 부분 적용 실패 시 기존 상태를 복구하고 결과를 확인한다. 네트워크 응답 유실을 실패로 단정해 무조건 새 조치를 제출하지 않는다.

조치 TTL 은 유효한 규칙이 유지될 기한이고 작업 제출 기한이나 사용자 변경 확정 기한과는 다르다. 재시작 뒤에도 복구할 수 있도록 활성 규칙과 기한을 영속 저장하고, 가능한 경우 데이터 경로 자체의 timeout 을 사용한다. 제어기와 별개인 만료 감시기가 복구를 확인한다. 지원하지 않는 장비에서는 이를 제공할 별도 실행부가 필요하며, 만료 기능이 있다는 선언만으로 해제를 보장하지 않는다.

stateful 경로에서는 이미 established 로 허용한 연결이 뒤쪽 차단 규칙을 계속 통과할 수 있다. 따라서 기존 연결까지 제한할 조치는 규칙 우선순위와 연결 상태 처리를 함께 검증해야 한다. 연결 상태 전체를 지우는 광범위한 작업 대신 해당 대상에 한정한 처리를 검토하고 세션 손실을 효과 평가에 포함한다. 실패나 시간 초과 시 기존 결정적 방어 정책을 유지하며, 사전 승인된 별도 규칙 없이 모델 오류만으로 강한 새 차단을 생성하지 않는다.

3 8 기존 라우터와의 연동 범위

연동 검토에는 로컬 Security Switch 구현 자료를 사용했다[14]. 작업 API 는 중복 요청 키, 기대 revision 및 검증 경로를 제공하므로 실행 어댑터의 기초로 사용할 수 있다. 다만 기존 자동 격리는 신뢰할 수 있는 DHCP 바인딩과 FDB·포트 상태 및 등록된 notice 규칙을 확인하는 경로다. Laya 결과를 notice 로 꾸며 제출하지 않고 모델 결정임을 나타내는 별도 검증 입력과 권한 경로를 설계해야 한다.

표 5 기존 구현과 제안 설계의 연결 지점

항목	소스에서 확인한 범위	추가 구현 또는 검증
이벤트 전달	활성 로그 수집 주기 1 초	조기 상태 이벤트와 센서 인접 저지연 스트림
QoS	기본 ingress policing 과 egress QoS 어댑터	연결별 제한 단위·물리 shaping·변경 지연
라우팅	정적 경로와 제한된 L3 ACL	사전 경로 프로필·무중단 전환·복구 검증
조건부 차단	ingress 및 egress ACL 경로	선택자별 지원 범위와 기존 연결 차단
호스트 격리	바인딩·FDB·notice 기반 격리	Laya 결정 전용 검증·권한·증거 연결
작업 관리	검증·중복 요청·revision·복구 구조	동적 조치 어댑터·규칙 TTL·재시작 시 복구

현행 routed ACL 생성기는 permit/drop 의 제한된 부분집합만 받고 rate-limit·expiry·일부 L2 및 패킷 선택자를 거부한다. 따라서 표 4 의 기능을 모든 경로가 이미 지원한다고 해석하면 안 된다. 또한 문서는 전체 설정 적용 중 데이터 링크 중단과 NAT 세션 초기화를 설명한다. 이 전체 재구성 경로를 매 탐지마다 호출하면 응답이 빠르더라도 정상 서비스 손실이 커질 수 있다. 사전 준비된 프로필과 소유 범위가 제한된 동적 규칙의 점진적 변경 경로는 후속 구현 과제다.

3 9 지연 예산과 부하 제어

$$T_{total} = T_{obs} + T_{ingest} + T_{prep} + T_{queue} + T_{model} + T_{policy} + T_{apply}$$

전체 시간은 공격을 식별할 수 있는 증거가 생기는 데 걸린 시간부터 실제 장비 적용까지다. 서비스 판정 시간은 요청 수신부터 구조화 결과 반환까지이며 입력 준비·큐·모델 계산을 포함한다. 기존 실험의 시간은 전처리된 window 조립부터 CPU 점수 반환까지여서 센서 전달과 장비 적용을 포함하지 않는다. 세 경계를 각각 기록하고 혼용하지 않는다.

표 6 판정 서비스 200ms 를 위한 초기 시간 예산

단계	예산	측정 및 초과 시 처리
입력 검증과 토큰화	20ms	정규화 캐시·토큰 수 기록, 부적합 입력 보류
대기열	20ms	기한 중심 스케줄, 동일 주체의 대기 갱신 병합
모델 계산과 점수 반환	140ms	워밍업·길이별 측정, 초과 결과는 조치에서 제외
보정과 결과 검증	20ms	버전·대상·출력 스키마 확인 후 반환

20+20+140+20=200ms 는 요청 수신 이후의 설계 예산이며 실측 결과가 아니다. 센서 수집과 장비 적용은 포함하지 않는다. 단계별 p95 를 더해 전체 p95 라고 보고하지 않고 동일 요청의 전체 경과 시간을 직접 측정한다.

기본 빠른 경로는 batch 1 로 시작한다. micro-batch 는 요청 기한 안에서만 묶으며 배치가 찰 때까지 무제한 기다리지 않는다. 주체별 상태 갱신은 모두 저장하고 실행 대기 중인 오래된 window 만 최신 revision 으로 대체한다. 대기열 상한에 도달하면 누락 및 보류를 기록하고 추가 분석으로 전환한다. 낮은 점수의 초기 필터가 최종 탐지 상한을 만들 수 있으므로 새 위협 탐지 경로 전체를 기존 탐지기의 양성 결과에만 종속시키지 않는다.

측정된 Laya 배치 128 처리량은 약 44.5 판정/초였지만 이는 직렬화가 제외된 다른 입력과 micro-batch 16 의 순차 실행 결과다. 이 수치로 실서비스 용량이나 적정 GPU 수를 바로 정하지 않는다. 주체별 요청률, 후보 병합률, 토큰 길이, 동시 요청 및 공격 중 급증을 반영한 부하 실험으로 용량을 정한다. 여러 worker 를 쓰면 한 주체의 revision 순서를 조정하고 모델 버전이 섞인 결과를 추적해야 한다.

3 10 비동기 설명과 온라인 처리 절차

설명 LLM 에는 판정 당시의 원본 증거, 제외·결측 정보, 정책 버전, 후보 점수, 제어기의 거부 또는 승인 이유, 장비 적용 결과를 전달한다. 출력에는 증거 ID 와 관측 사실, 공격 가설, 불확실성, 실제 조치를 구분하도록 한다. 설명은 판정과 다를 수 있으며 불일치 자체를 검토 대상으로 기록한다. LLM 의 설명을 자동으로 정답 라벨에 편입하거나 이미 실행된 조치를 정당화하는 문장으로만 제한하지 않는다.

알고리즘 1 사건 도착에 따른 판정과 조치

1 사건의 출처·스키마·시각을 검사하고 중복을 제거한 뒤 증거 저장소에 기록한다.

2 관련 주체와 연결 상태를 갱신하고 현재 도착한 자료만으로 새 window revision 을 만든다.

3 입력 품질·토큰 예산·지원 기능을 확인하고 기한을 갖는 판정 요청을 등록한다.

4 Laya 점수를 보정하고 품질 부족·낮은 확신·시간 초과는 보류 상태로 반환한다.

5 정책 제어기는 최신 대상 바인딩·revision·허용 기능을 확인해 조치 또는 관측 유지를 정한다.

6 실행 의도를 멱등 작업으로 제출하고 readback·집행 확인 후 활성 상태와 만료 시각을 기록한다.

7 원본 증거와 판정·실행 결과를 설명 큐에 전달하고 기한 만료 또는 실패 시 복구를 확인한다.

이 절차에서 Laya 의 역할은 관측 문맥의 판정이며, 권한 부여·원본 대상 해석·장비 실행은 결정적 코드가 담당한다. 모델이 이용 가능한 언어 정보를 빠른 의사결정에 활용하고, 설명 생성의 지연은 초기 조치 경로에서 분리하는 것이 설계의 핵심이다.

4 연관 탐지와 대응 선택을 위한 학습 설계

4 1 데이터 구성과 정답 단위

완료된 NF-UNSW-NB15-v2 실험의 행 라벨은 마지막 흐름의 공격 여부다. 이 라벨만으로 window 전체의 위험 수준이나 최적 대응 조치를 만들 수 없다. 확장 학습에서는 시각과 주체 관계를 보존한 공개

네트워크 PCAP·로그를 사용하고, 사건 묶음이 정상 운영인지 공격 실행의 일부인지 시나리오 단위로 확인한다. 조기 시점에 증거가 충분하지 않은 prefix 는 최종 공격 라벨을 기계적으로 복사하지 않고 판단 가능성 또는 보류 대상으로 구분한다.

정상 업데이트, 백업, 서비스 점검처럼 공격과 비슷한 동작을 하는 정상 사례를 포함한다. 단일 마지막 사건의 표현은 같지만 앞선 관계가 달라 정답이 달라지는 짝을 만들고, 관계를 바꾼 뒤에도 네트워크 시나리오가 성립하는지 검토한다. 자동으로 섞은 로그만으로 의미적 연관 정답을 만들지 않는다. ATT&CK 와 mitigation 은 기법·방어 개념을 매핑하는 자료로 사용하며 로그 라벨이나 최적 조치의 대체 정답으로 사용하지 않는다[10].

대응 학습의 레코드는 관측 문맥, 자산 역할, 허용 기능, 적용 범위, 전문가 또는 재생 검증으로 정한 허용 조치, 정상 손실 및 공격 억제 결과를 포함한다. 여러 조치가 합리적이면 하나를 임의로 유일 정답으로 정하지 않고 근거 있는 목표 분포나 허용 집합을 기록한다. 조치를 시험하지 않은 공개 탐지 데이터에는 대응 정답이 없다고 표시한다. 실제 피해 비용이 없는 경우 조치의 정답 일치율을 피해 감소 효과로 바꾸어 해석하지 않는다.

4 2 손실 함수와 단계별 파인튜닝

$$L = L_{det} + \lambda_{sev}\, m_{sev}\, L_{sev} + \lambda_{act}\, m_{act}\, L_{act} + \lambda_{lang}\, L_{lang}$$

L_det 은 위협 여부 손실, L_sev 와 L_act 는 위험 수준과 조치의 교차엔트로피 또는 목표 분포 손실이다. m 은 해당 정답이 존재하는 표본에서만 1 인 마스크다. L_lang 은 언어 판정 능력을 유지하기 위한 보조 손실이며 각 λ 는 독립 검증 구간에서 정한다. 이 식은 제안 학습 목표로, 완료된 실험에는 L_det 만 사용했다.

표 7 확장 모델의 단계별 학습과 검증

단계	학습 범위	다음 단계의 판단 근거
입력과 정답 검증	도착 시각·관계·목표·정답 마스크 점검	미래 정보·중복·대상 혼동이 없는 표본
위협 판정 적응	기존 이진 Laya 를 관계 window 로 학습	동일 오탐률에서 단일 사건보다 높은 탐지율
선택지 그룹 확장	그룹별 마커와 위험·대응 손실 추가	유효 정답 표본의 조치·위험 수준 성능
언어 능력 보존	정책 바꿔쓰기·필드 다양화·보조 증류	원본 모델과 학습 후 모델의 언어 대조
보정과 임계값	동결 모델을 독립 검증 자료로 보정	자연 발생 비율에서 확률 품질·조치 비용
고정 평가	seed·코드·모델·정책 버전 고정	미학습 공격·지연·정상 손실까지 동시 보고

초기 탐색은 기존에 사용한 Adam 학습률 0.00001 을 출발점으로 하되, 0.000005 와 0.00002 를 검증 구간에서 비교한다. 처음부터 전체 인코더를 갱신하는 경우와 판정 경로만 적응시킨 뒤 인코더를 갱신하는 경우를 대조한다. 출발값은 기존 실행 가능성에 근거한 가정이며 최적값을 뜻하지 않는다. 예산이 다른 무제한 탐색 대신 비교 모델마다 고정된 시행 수와 조기 종료 기준을 정하고 세 seed 의 분산을 보고한다.

언어 능력을 보존하는 후보 방법은 정책의 의미를 유지한 바꿔쓰기, 필드명·표현 다양화, 원본 모델의 일반 판정 분포를 보존하는 증류다. 보조 표본 비율 0·10·20%를 비교해 탐지와 언어 성능의 변화를 따로 확인한다. 교사의 판단을 보안 정답으로 신뢰하거나 보조 학습이 반드시 미학습 위협 성능을 높인다고 가정하지 않는다. 확장 act/escalate 학습이 없다면 기존 헤드의 보류 점수도 자동 조치 근거로 사용하지 않는다.

4 3 분할과 확률 보정

학습·검증·테스트는 공격 실행과 수집 세션을 기준으로 분리한다. 시간 순서를 보존하고 중첩 window 와 동일 패킷이 경계를 넘지 않게 한다. 분할을 고정한 뒤 window 와 익명 토큰을 생성한다. 미학습 공격 평가는 공격 계열 또는 시나리오를 학습과 검증에서 모두 제외하고, 배경 정상 트래픽은 배포 조건에 가깝게 유지한다. 공격 계열 미학습과 새로운 날짜·환경의 분포 변화는 별도 실험으로 보고한다.

정상·공격 균형 배치로 학습하면 실제 운영의 발생 비율과 달라질 수 있으므로 학습 점수 0.5 를 곧바로 운영 임계값으로 사용하지 않는다. 온도 보정은 검증할 수 있는 후보 방법이다[13]. 위험 수준·대응 점수도 각각 평가하며, 온도 보정만으로 기저율 변화나 새로운 공격에 대한 확률 품질이 보장되지는 않는다. 자연 발생 비율의 별도 검증 구간에서 PR-AUC, Brier score, ECE 및 임계값별 오탐을 확인하고 모델·보정·정책을 함께 버전 관리한다.

검증 구간에서 모델 선택과 보정에 같은 표본을 반복 사용하면 낙관성이 생길 수 있으므로 검증 자료를 선택용과 보정용으로 분리하거나 교차 적합한다. 최종 테스트는 한 번 고정 평가에 사용한다. 기존 실험의 테스트 기반 학습률 선택을 확장 연구에 그대로 반복하지 않는 것이 평가 설계의 변경점이다.

5 공개 데이터 기반 학습과 평가 방법

5 1 데이터와 분할

실험은 UQ 공식 NF-UNSW-NB15-v2 의 2,390,275 개 흐름을 사용했다[8]. 원본 행 순서에서 앞 2,151,248 행을 학습 구간으로, 뒤 239,027 행을 평가 구간으로 나눴다. 평가 구간에는 공격 16,271 개와 정상 222,756 개가 있다. 저자 코드가 선택한 37 개 특성을 사용하고 IP 주소, 정답 Label 과 공격 이름 Attack 은 입력에서 제외했다. 수치 변환 및 빈도가 낮은 범주 처리는 학습 구간에서 적합했다. 입력은 연속 여덟 행이며 마지막 행의 이진 라벨이 정답이다.

원문은 90:10 분할을 기술하지만 공개 UNSW 예제에는 97.5:2.5 가 사용돼 있다[1,11]. 본 연구는 90:10 을 채택하고 구체적인 행 경계와 해시를 남겼다. 원문의 정확한 평가 행과 최적 학습률·seed 가 공개되지 않았으므로 본 결과를 논문 발표값과 완전히 동일한 재현이라고 부르지 않는다. 또한 v2 CSV 에는 흐름 시작 시각이 없으며 행의 인접성이 같은 호스트나 공격 단계의 연결을 보장하지 않는다. 이 평가 단위는 시간 기반 Zeek 연관 window 와 구별된다.

5 2 학습 설정과 완료 범위

실험용 Laya 입력은 여덟 흐름의 전처리 특성과 열 이름, 마지막 행의 공격 여부를 묻는 영어 지시문이다. float32 값을 보존하도록 유효숫자 아홉 자리의 CSV 로 직렬화했다. 최대 입력 길이는 8,192 토큰으로 설정했고 두 완료 실행의 관측 최대 길이는 2,080 토큰과 2,074 토큰이었다. 입력을 잘라내는 표본은 거부했다. 이는 제 3 절의 Zeek 관계 window 와 다중 선택지 확장을 사용한 실험이 아니다.

비교군은 Shallow Encoder, Shallow Decoder, GPT 구조, BERT 구조의 각 두 설정이다. seed 20261005, 20261006, 20261007 별 표본 스케줄을 사전에 고정해 모든 모델에 동일하게 공급했다. 유효 배치는 128 개로 정상·공격 각 64 개이며, epoch 당 64 개 배치를 추출한다. 따라서 한 epoch 는 학습 구간 전체를 한 번 순회한다는 뜻이 아니라 8,192 회 표본 추출이다. 최대 20 epoch 와 원본 코드의 최소 개별 배치 손실에 기반한 조기 종료를 사용했다.

Laya 는 학습률 0.00001 의 Adam 과 false/true 점수에 대한 교차엔트로피로 인코더 및 판정 경로를 파인튜닝했다. 이진 판정에 사용하지 않는 act/escalate 헤드는 고정했으며 학습 가능한 파라미터는 421,029,889 개다. micro-batch 8 과 누적 16 회로 유효 배치 128 을 맞췄다. 가중치는 float32, 계산은 BF16 autocast 와 SDPA 를 사용했다. 기본 모델의 RLCD 학습 설명과 이번 지도학습을 혼동하지 않으며, 파인튜닝 뒤 확률 보정은 수행하지 않았다.

$$L(\theta) = -(1/N) \sum_i log\ p_\theta(y_i \mid W_i, q)$$

비교군은 학습률 0.01, 0.001, 0.0005, 0.0001, 0.00001 의 다섯 값에서 각 세 번 실행했다. 기본 BERT 설정의 수렴 실패 후 추가 탐색 조건을 정했으며 Laya 의 첫 테스트 평가 전에 고정했다. 비교군 총 120 회 중 119 회가 완료되고 한 번은 수치 발산했다. Laya 는 세 번 중 두 번이 각각 17·12 epoch 에서 종료된 뒤 전체 평가를 마쳤다. 세 번째는 학습 중단으로 평가하지 않았으며 본문에 성적을 부여하지 않았다. 속도 보강 시에는 저장된 가중치의 추론만 수행했다.

각 비교군의 학습률은 세 반복 평균 테스트 F1 로 선택했다. 이 선택에는 테스트 기반 낙관성이 있고 Laya 는 한 학습률만 사용했으므로 탐색량도 비대칭이다. 결과는 관측된 비교이며 통계적으로 확정된 모델 일반의 우열로 해석하지 않는다. 테스트 성적이 가장 좋은 epoch 를 고른 것은 아니며, 주 평가 체크포인트는 정해진 학습 종료 시점의 가중치다.

5 3 정확도와 속도 지표

탐지 지표는 F1, 공격 탐지율, 정상 흐름의 오탐률과 혼동행렬이다. 평균과 표본 표준편차를 보고하고, 반복 수가 적어 표준편차를 신뢰구간으로 해석하지 않는다. 모든 공격 종류가 학습 구간에 포함돼 있으므로 이 결과는 미학습 공격 평가가 아니다. 학습 구간과 같은 특성값이 있는 평가 행을 제외한 하위 집단도 별도로 집계하되, 이를 새로운 독립 테스트셋이나 중복 제거 재학습 결과로 부르지 않는다.

추론은 같은 RTX 4090 에서 모델을 순차 실행했다. 비교군은 이미 선택한 학습률의 첫 seed, Laya 는 첫 완료 seed 를 사용했으며 두 번째 Laya 는 단일 요청 지연만 추가 확인했다. 각 배치 크기 1·8·128 에 네 배치를 워밍업한 뒤 고정된 50 개 무작위 학습 배치를 각각 네 번 측정했다. 처리량은 배치별 네 반복의 중앙값을 50 개 배치에 대해 평균한 시간으로 계산했다. p50·p95 는 입력 준비를 포함한 단일 요청 200 개의 원시 지연에서 직접 계산했다.

단일 요청은 같은 50 개 window 의 네 반복이며 독립적인 200 개 입력이 아니다. 모델 로딩, 최초 컴파일, 원시 로그 파싱·수치 정규화, window 수집 대기, 동시 요청 큐, 네트워크 및 장비 적용은 제외했다. 비교군은 TensorFlow 2.15.1 float32, Laya 는 PyTorch 2.8.0+cu128 의 BF16 autocast 를 사용했다. WSL2 에서 화면 출력에도 쓰는 GPU 를 사용했고 측정 직전 네 차례 사용률은 0~2%였다. 운영체제 간섭을 완전히 제거한 전용 장비의 장시간 부하 시험은 아니다.

6 실험 결과

6 1 탐지 성능

표 8 선택한 학습률에서의 탐지 성능

모델	학습률	반복	F1 %	탐지율 %	오탐률 %
Encoder Dense	0.0005	3	94.36 ± 0.20	99.674	0.847
Encoder Projection	0.0005	3	94.49 ± 0.20	99.756	0.832
Decoder Last	0.0001	3	94.15 ± 0.36	99.816	0.893
Decoder Flatten	0.0005	3	94.00 ± 0.85	99.777	0.915
GPT Lookup	0.0001	3	91.66 ± 0.36	99.693	1.303
GPT Dense	0.0001	3	93.97 ± 0.71	99.746	0.917
BERT None	1e-05	3	66.66 ± 46.69	99.736	33.976

모델	학습률	반복	F1 %	탐지율 %	오탐률 %
BERT Projection	1e-05	3	39.30 ± 45.99	99.934	67.062
Laya	0.00001	2	93.90 ± 0.79	99.948	0.946

F1 은 평균 ± 표본 표준편차다. 비교군은 테스트 F1 로 학습률을 선택했으며 Laya 와 탐색량이 다르다. GPT·BERT 는 사전학습 상용 언어모델이 아닌 저자 코드의 비교 구조다.

Laya 의 평균 F1 은 93.90%로 최상 비교군 Encoder Projection 의 94.49%보다 0.59%p 낮았다. 공격 탐지율은 99.948%로 비교군 99.756%보다 높았지만 오탐률은 0.946%로 비교군 0.832%보다 높았다. 같은 두 seed 만 비교해도 F1 은 93.90% 대 94.44%로 Laya 가 0.55%p 낮았다. 평균 누락은 46.0 개에서 8.5 개로 감소한 반면 평균 오탐은 1,863.5 개에서 2,107.0 개로 증가했다. 놓치는 공격을 줄이는 방향의 변화와 정상 서비스에 부담을 주는 변화가 함께 관측됐다.

표 9 Laya 와 Encoder Projection 의 공통 seed 혼동행렬

모델과 seed	TP	FP	TN	FN
Laya 20261005	16267	1907	220849	4
Encoder 20261005	16239	1814	220942	32
Laya 20261006	16258	2307	220449	13
Encoder 20261006	16211	1913	220843	60

Laya 의 평균 정밀도는 88.54%이고 정상 흐름 10,000 개당 평균 오탐은 94.6 개다. 이를 실제 호스트 차단 수로 환산할 수는 없지만, 공격 점수만으로 강한 차단을 자동 적용하기에는 조치 단위의 검증이 필요함을 보여준다. BERT 계열의 큰 표준편차와 높은 오탐률은 일부 반복이 거의 모든 흐름을 공격으로 판정한 결과다. 이 수렴 실패를 BERT 계열 전반의 한계로 일반화하지 않는다.

평가 행 59,793 개인 약 25.02%는 학습 구간에도 동일한 37 개 특성 조합이 존재했다. 이들을 제외한 179,234 개에서 Laya 평균 F1 은 92.21%, 탐지율은 99.952%, 오탐률은 1.250%였다. 동일 특성의 존재는 같은 원본 패킷이나 연결의 중복 수집을 확인한 것은 아니다. 하위 집단의 공격 비율도 달라지므로 F1 차이를 모두 암기 효과로 설명하지 않는다.

6 2 추론 지연과 배치 처리량

표 10 같은 RTX 4090 에서 측정한 추론 지연과 처리량

모델	p50 ms	p95 ms	배치 8 판정/초	배치 128 판정/초
Encoder Dense	10.50	15.21	546.1	7741.2
Encoder Projection	10.53	16.22	536.8	7659.3
Decoder Last	11.05	19.92	529.2	7967.2
Decoder Flatten	10.60	16.36	545.0	7661.0
GPT Lookup	18.90	54.79	148.2	2360.8

모델	p50 ms	p95 ms	배치 8 판정/초	배치 128 판정/초
GPT Dense	18.84	63.39	181.6	2621.2
BERT None	13.65	36.17	174.5	2433.5
BERT Projection	14.16	42.64	179.3	2583.0
Laya	29.61	80.03	43.3	44.5

p50·p95 는 입력 준비를 포함한 단일 요청 지연이다. 처리량은 사전 인코딩한 입력부터 CPU 점수 반환까지이며 직렬화·토큰화는 제외한다. Laya 배치 128 은 micro-batch 16 을 순차 실행했다. 한 판정은 8 개 흐름 window 의 마지막 흐름에 대한 판정이다.

Laya 첫 체크포인트의 p50 은 29.61ms, p95 는 80.03ms 였고 두 번째는 각각 28.53ms 와 76.37ms 였다. 각 체크포인트의 200 회 요청은 모두 200ms 이내였으며 관측 최대 지연은 각각 112.89ms 와 88.93ms 였다. 이 결과는 워밍업된 로컬 추론 경로에서 정한 지연 목표의 충족을 보여준다. 다만 p95 의 표본 크기가 작고 장시간 부하·동시 요청 조건이 아니므로 운영 SLA 를 보장하지 않는다.

Encoder Projection 의 p95 는 16.22ms 로 Laya 첫 체크포인트보다 약 4.9 배 짧았다. 따라서 Laya 가 이번의 작은 탐지기보다 빠르다는 주장은 성립하지 않는다. 모델 크기도 약 35 만 대 4 억 2 천만 파라미터로 크게 다르다. 이 차이에 입력 길이와 프레임워크가 함께 작용했으므로 Projection 하나만의 인과 효과를 추정하지 않는다. 생성형 LLM 의 같은 질문에 대한 응답 지연은 측정하지 않아, 본 실험으로 LLM 대비 가속 배율을 산출할 수는 없다.

Laya 의 사전 인코딩 입력 처리량은 배치 8 에서 43.3 판정/초, 배치 128 에서 44.5 판정/초였다. 배치를 크게 해도 물리 배치 16 으로 나누어 처리하는 조건에서는 증가 폭이 작았다. 단일 요청이 빠르다는 사실과 많은 요청이 동시에 도착할 때의 대응 능력은 다르다. 운영에서는 입력 준비, 배치 채움 대기, 큐 적체를 포함한 지연과 용량을 함께 측정해야 한다.

7 논의

7 1 진일보한 방향의 의미

본 연구가 지지하는 진전은 언어모델 기반 보안 시스템의 역할 배분에 있다. 위협의 설명을 생성하는 능력과 즉시 실행할 결정을 반환하는 능력을 별도 경로로 구성하면, 초기 대응이 설명 생성의 완료를 기다릴 필요가 없다. Laya 는 자연어로 기술한 질문과 선택지를 처리하는 구조를 유지하면서 로컬 추론 p95 200ms 이내를 달성했다. 이는 언어모델의 활용 범위를 실시간 판정으로 넓히려는 방향의 실현 가능성을 보여준다.

여기서 언어모델의 장점을 유지한다는 표현은 사전학습 인코더와 언어 기반 판정 인터페이스를 유지한다는 구조적 의미로 한정한다. 기존 LLM 과 같은 수준의 보안 추론, 새로운 공격의 이해, 정책 변경에 대한 일반화가 유지됐다고 주장하지 않는다. 원래 Laya 의 지시문 처리 능력도 보안 파인튜닝으로 달라질 수 있으므로, 학습 전후의 언어·보안 평가가 필요하다. 설명 생성을 제거한 구조적 이점은 방향의 근거이며, 실제 탐지 우위는 별도 실험의 대상이다.

기존 Encoder Projection 은 수치 흐름 분류에서 더 좋은 F1·오탐·지연을 보였다. 따라서 이번 조건에서의 대체 근거는 부족하다. 그러나 이 결과만으로 두 모델의 의미적 연관 탐지 능력까지 비교했다고 볼 수도 없다. Laya 가 더 유리할 가능성이 있는 과제는 형식이 다른 사건과 자연어 정책을 함께 해석해야 하는 판정이며, 그 가능성은 과제에 맞는 데이터로 검증해야 한다. 속도 목표 충족, 탐지 성능 개선, 연관 의미 이해의 보존을 서로 다른 주장으로 다루는 것이 필요하다.

7 2 현재 평가가 설명하지 못하는 부분

첫째, 입력에서 호스트 식별자를 제외하고 시작 시각을 제공하지 않았으므로 다단계 공격의 주체·시간 관계를 충분히 나타내지 못했다. 둘째, 단일 흐름 대조 학습이나 문맥 제거 평가가 없어 성적이 문맥 활용에서 비롯됐는지 알 수 없다. 셋째, 공격 계열을 학습에서 제외하지 않아 미학습 위협 탐지율을 제시할 수 없다. 이 제약은 두 모델 모두에 적용되며 어느 한 모델의 능력 부재를 뜻하지 않는다.

넷째, Laya 는 두 반복만 완료됐고 비교군의 테스트 기반 학습률 선택과 비대칭 탐색이 있다. 다섯째, 데이터의 행 순서 분할이 원문과 정확히 같은지 확인할 수 없고, 동일 특성 중복도 존재한다. 여섯째, 정밀도·optimizer 세부값·학습 GPU 가 다르며 BERT 의 모델 전체 XLA JIT 을 비활성화한 재현 차이가 있다. 속도는 같은 RTX 4090 에서 다시 측정했지만 커널과 프레임워크까지 동일하게 통제한 비교는 아니다.

일곱째, Jev 의 수치는 관련 문헌의 결과이며 이번 장치와 데이터에서 실행한 결과가 아니다. 기존 생성형 LLM 이 같은 네트워크 위협 판정에서 얼마나 느린지에 대한 대조군도 없다. 모든 LLM 이 수초 이상 걸린다거나 Jev·Laya 가 일반적으로 200ms 를 보장한다고 확대하지 않는다. 짧은 선택지 출력이나 next-token 점수 방식의 LLM 도 비교해야 한다. 마지막으로, 형식이 제한된 출력도 잘못된 공격 판단이나 잘못된 조치를 만들 수 있으며 확률 보정은 도메인별로 다시 확인해야 한다.

8 연관 탐지와 자동 대응을 위한 후속 검증

8 1 관계를 보존하는 공개 네트워크 평가

후속 평가의 기본 단위는 시간과 주체가 유지된 네트워크 사건 묶음으로 정한다. 공개 PCAP 또는 시각·주소가 보존된 로그에서 Zeek 기록을 만들고, 분할 전에 공격 시나리오와 수집 구간을 구분한다. 같은 공격 실행이나 중첩 window 가 학습·검증·평가를 가로지르지 않게 하며 주소는 분할 누수를 피하면서 관계를 유지하는 익명 식별자로 표현한다. 단순히 IP 를 제거하면 일반화 누수는 줄일 수 있지만, 필요한 관계 정보까지 사라질 수 있다는 점을 함께 고려한다.

문맥이 필요한 평가 집단은 마지막 사건만으로 정답이 결정되지 않는 사례로 구성한다. 예를 들어 비슷한 연결이 정상 관리 작업의 일부인지, 같은 주체의 탐색·반복 통신과 결합된 공격 단계인지 구분하도록 한다. 같은 형식의 정상 업데이트·백업 사례를 포함하고, 문맥을 바꿀 때 정답도 전문가 또는 재현 시나리오에 따라 검증한다. 단순히 문맥을 섞었을 때 모델 점수가 달라지는 현상만으로 올바른 연관 추론을 입증하지 않는다.

표 11 후속 실험에서 필요한 대조 조건

검증 목적	대조 조건	핵심 지표
문맥의 실제 기여	단일 사건 학습 대 전체 window 학습	같은 오탐률의 사건 탐지율
관계 정보의 기여	호스트·시간 관계 유지 대 통제된 관계 변경	정답 변화에 대한 판정 일관성
미학습 공격 일반화	공격 계열·시나리오를 통째로 평가에 보류	미학습 공격 탐지율과 정상 오탐
언어 장점의 유지	원본·파인튜닝 모델과 사전학습 제거 대조	정책 바꿔쓰기·새 필드·새 조합 성능
생성형 모델 대비 효율	설명 생성·짧은 결정·선택지 점수 방식	같은 정확도 조건의 p95 와 처리량
자동 대응 효과	탐지만 수행 대 정책 적용을 포함한 재생	확산 범위·차단 시간·정상 서비스 손실

8 2 학습과 보정 및 정책 평가

학습은 이진 위협 판정에서 시작하되, 연관 증거가 필요한 사례와 정상 유사 사례를 늘리는 방식으로 확장한다. 위협 유무, 위험 수준, 허용 대응 후보의 목표를 구분하고 대응 후보에는 미조치·추가 분석도 포함한다. ATT&CK 매핑이나 LLM 설명을 자동 정답으로 확정하지 않고, 공개 시나리오의 실제 라벨과 전문가 확인으로 검증한다. 자연어 표현 다양성을 유지하는 학습이나 기존 모델의 출력 분포를 보존하는 증류는 후보 방법이며, 효과를 입증하려면 해당 항목을 제거한 대조 실험이 필요하다.

확률 보정과 조치 임계값은 독립 검증 구간에서 결정하고 테스트셋을 사용하지 않는다. 같은 오탐률에서의 탐지율, PR-AUC, Brier score, ECE, 판정 보류 비율과 위험을 함께 보고한다. 조치 정답의 일치율뿐 아니라 정상 연결 단절, 서비스 지연 증가, 공격 확산 감소도 재생 환경에서 측정해야 한다. 정책이 정한 기능 목록과 모델의 선택지를 같은 버전으로 기록해 변경 후에도 결과를 추적할 수 있게 한다.

지연 평가는 정상 요청률과 공격 중 급증 구간을 나눠 수행한다. 토큰 수, window 길이, 동시 요청 수, 실제 물리 배치, 큐 길이별 p50·p95·p99 를 기록하고 공격 발생부터 조치 적용까지를 계측한다. Laya·Jev·생성형 LLM 을 비교할 때에는 입력 증거와 판정 목표를 맞추고, 로컬 계산 시간과 네트워크를 포함한 서비스 지연을 별도로 보고한다. 이 조건이 갖춰져야 언어모델의 장점을 유지하면서 대응을 앞당겼다는 주장을 직접 검증할 수 있다.

8 3 구현 인수와 장애 재생 평가

확장 시스템의 인수 평가는 탐지 정확도와 실행 정확도를 나누어 진행한다. 입력 계약과 조치 어댑터를 격리된 재생 환경에서 먼저 검증하고, 이후 조치를 적용하지 않는 관찰 모드에서 요청률과 판정을 측정한다. 제한된 대상과 복구 가능한 조치로 실행 평가를 확장하면서 모델·정책·장비 버전을 고정한다. 아래 항목은 후속 시험의 통과 기준이며 이미 시험에 성공했다는 결과가 아니다.

표 12 설계 인수를 위한 기능 및 장애 대조

재생 조건	필수 동작	보고 지표
지연·중복·역순 사건	도착 전 정보 사용 금지와 원본 사건 중복 제거	미래 정보 사용·중복 판정·보류 수
NAT·임대 갱신·공유 포트	확정되지 않은 호스트의 강한 조치 거부	오대상 조치 수와 대상 해석 성공률
누락·초과 길이·악의적 로그	품질 저하 표시와 정책 구역 보호	누락 탐지·주입에 따른 판정 변경률
모델 지연·장애·과부하	기한 초과를 정상으로 반환하지 않음	완료·보류 비율과 전체 요청 p95·p99
중복 의도·revision 충돌	동일 작업 반환 또는 최신 상태 재검증	중복 적용 수와 충돌 처리 결과
신규·기존 연결 차단	허용 범위에만 규칙을 적용하고 실제 집행 확인	차단 성공·정상 연결 손실·세션 영향
재시작·부분 적용·만료	영속 기한 확인과 복구 또는 명시적 실패	복구 시간·잔류 규칙·복구 실패 수
지속 공격과 정상 혼합	조치 없는 대조군과 같은 트래픽을 재생	확산 범위·차단 시간·서비스 손실

관계 활용의 효과는 단일 사건, window, 관계 필드 제거, 통제된 관계 변경을 같은 표본과 오탐 조건에서 비교한다. 성공한 요청만 추려 지연을 보고하지 않고 모든 요청의 대기·보류·기한 초과를 포함한다. p95 200ms 충족 여부와 탐지율을 함께 보고해 느린 사례를 버리는 방식으로 목표를 만족하는지 확인한다. 장비 적용은 별도 종단 지연과 정상 서비스 손실을 보고하며, 후속 확장 모델이 기존 이진 모델보다 진일보했는지는 이 조건을 만족한 뒤 평가한다.

9 결론

본 연구는 Laya 아키텍처를 이용해 언어 기반 위협 판정을 빠른 대응 경로에 배치하고, 별도 생성형 LLM 이 상세 설명을 담당하는 구조를 제안했다. 공개 네트워크 흐름 데이터에서 학습한 두 Laya 체크포인트는 RTX 4090 의 입력 준비 포함 단일 요청 p95 76.37–80.03ms 를 보여, 이번 추론 경로의 200ms 목표를 충족했다. 결과는 언어 사전학습을 활용하는 비생성형 판정 계층을 저지연 보안 시스템에 넣을 수 있다는 실증 근거다.

동시에 Laya 의 평균 F1 과 오탐률은 최상 비교군보다 불리했고 추론도 더 느렸다. 따라서 현재 결과로 기존 탐지기보다 우수한 모델을 완성했다고 결론내릴 수 없다. 본 연구가 제시하는 진일보는 설명 생성에 묶여 있던 초기 판정을 분리하고, 언어 기반 정책 해석의 가능성과 짧은 응답 경로를 함께 추구하는 설계 방향이다. 그 방향이 실제 연관 위협 탐지와 공격 확산 억제로 이어지는지는 관계를 보존한 데이터, 미학습 공격 대조, 확률 보정 및 정책 실행 평가로 확인해야 한다.

참고문헌

[1] L. Daly Manocchio, S. Layeghy, W. W. Lo, G. K. Kulatilleke, M. Sarhan, and M. Portmann. FlowTransformer: A Transformer Framework for Flow-based Network Intrusion Detection Systems. arXiv:2304.14746v1, 2023. 원문

[2] B. Warner et al. Smarter, Better, Faster, Longer: A Modern Bidirectional Encoder for Fast, Memory Efficient, and Long Context Finetuning and Inference. ACL 2025, pp. 2526–2547. DOI 10.18653/v1/2025.acl-long.127. 원문

[3] Convai Innovations. Laya model card and open model. 본 실험의 가중치 리비전 7b928d828b7b0e022f929d9bd2e44165aa270148. 모델 계열의 최신 설명과 사용 체크포인트를 구분함. 열람 2026-10-07. 원문

[4] D. Almeida. Introducing System One Models & Jev. TypeSafe AI, 2026-09-15. 개발사 기술 소개 자료. 원문

[5] T. Deußer, L. Sparrenberg, and R. Sifa. Evaluating and Benchmarking the System One Model Jev. arXiv:2609.37647v1, 2026-09-29. 사전공개 논문. 원문

[6] J. A. dos Santos Barbosa. Calibrated Decision Models for Autonomous Penetration-Testing Harnesses: JEV and Laya as System One Decision Layers for LLM-Driven Pentest Agents. arXiv:2609.28940v1, 2026-09-24. 사전공개 논문. 원문

[7] M. DiGiuseppe and S. Denney. JEV versus LLMs: Accuracy, Cost and Calibration on Seven Political Science Replications. arXiv:2610.06625, 2026-10-05. 사전공개 논문. 원문

[8] University of Queensland. ML-Based NIDS Datasets. NF-UNSW-NB15-v2 데이터 안내 및 공식 배포. 열람 2026-10-07. 원문

[9] Zeek Project. conn.log. Book of Zeek 9.0.0. 네트워크 연결 로그의 시각, 주체, 대상 및 연결 식별자 정의. 열람 2026-10-07. 원문

[10] MITRE. Working with ATT&CK. 공격 기법 및 완화 지식의 활용 자료. 열람 2026-10-07. 원문

[11] L. Daly Manocchio. FlowTransformer source code. 본 실험 고정 커밋 52236c8c9feccdeb44acf578789db7b8b36bacea. 원문

[12] Zeek Project. Protocol independent events. new_connection, connection_status_update, connection_state_remove. Book of Zeek. 열람 2026-10-07. 원문

[13] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger. On Calibration of Modern Neural Networks. Proceedings of ICML, PMLR 70:1321–1330, 2017. 원문

[14] Security Switch. 구현 문서와 소스 스냅샷. README, Zeek 운영 문서, telemetry 수집기, 정책·작업 API, 라우팅 ACL 및 자동 격리 구현. 2026-10-07 열람. 공개 문헌이 아닌 연동 대상의 로컬 소프트웨어 자료이며 위치와 해시는 부록 B 및 문서 manifest 에 기록한다.

부록 A 재현 자료와 수치 추적

본 논문의 탐지 수치는 학습 중단 시점의 저장된 예측에서 산출했고, 속도는 이후 저장된 체크포인트의 추론만으로 보강했다. 이전 v1–v4 실험과 서로 다른 Qwen 평가값을 동일 조건의 결과로 혼합하지 않았다. 두 Laya 의 전체 평가 행 번호·정답·예측 확률은 로컬 파일로 보존했으며 SHA-256 과 혼동행렬을 검증했다. 비교군 119 회의 원본 예측은 실험 서버에 보존하고 전체 시도별 성적과 예측 파일 해시는 로컬 증거 묶음에 보존했다.

표 A1 본문 수치의 원본 위치

근거	v5 디렉터리 기준 위치
탐지 집계와 공통 seed 비교	stopped/summary.json
비교군 전체 학습률과 반복	runs/grid_comparison.json 및 grid_results.csv
Laya 전체 평가 예측	runs/laya_seed20261005_predictions.npz 및 seed20261006 파일
요청별 원본 추론 시간	speed/*_seed*.json 및 verified_summary.json
가중치와 실행 소스 해시	speed/checkpoint_audit.json
측정 조건과 장치 사전 상태	speed/protocol.json 및 preflight.json
종합 보고서와 증거 묶음	STOPPED_REPORT.ko.md 및 stopped_report_and_evidence.zip

위 경로는 실험 자료의 위치이며 공개 저장소에 업로드됐다는 뜻은 아니다. 재현용 데이터는 UQ 공식 배포에서 확보한다. 모든 속도 결과는 가중치 해시의 측정 전후 일치를 확인했다.

데이터와 모델의 식별값은 다음과 같다. 전체 원본·체크포인트·소스 해시는 위 실험 자료에서 추적할 수 있다.

NF-UNSW-NB15-v2 CSV SHA-256

05019e3ac8d55b3f074f9f042623bbbb1af2527b8b78558c69353ccb2ccefa3f

Laya 기본 모델 리비전

7b928d828b7b0e022f929d9bd2e44165aa270148

FlowTransformer 코드 커밋

52236c8c9feccdeb44acf578789db7b8b36bacea

추론 측정 프로토콜 SHA-256

4848396c3b20d4d37b12c6b16f82924d824e9d6d8d7784ae5e42af8baee9aac0

부록 B 설계 근거와 구현 자료

참고문헌 [14]는 연동 대상의 로컬 소프트웨어 자료다. 확인한 코드의 기능 범위를 설계에 반영했으며 실제 운영 장비의 설정이나 성능을 재검증한 결과는 아니다. 각 파일의 전체 SHA-256 은 본 논문의 design_paper_manifest.json 에 기록한다. 원본 위치는 security_router 저장소 기준이다.

표 B1 연동 설계 판단의 코드 근거

확인한 내용	원본 위치
로그 수집 1 초 루프	internal/telemetry/store.go
수집·배포 및 기능 제약	docs/zeek-operations.md 및 README.md
QoS 구현과 남은 검증	docs/implementation-status.md
작업 API 와 요청 계약	internal/control/api.go 및 types.go
권한·revision 과 작업 처리	internal/control/engine.go
신뢰 바인딩과 notice 격리	internal/control/automation.go
routed ACL 제한과 규칙 순서	internal/backend/routing_policy.go

Laya 다중 선택지 그룹은 vendor/laya/laya/common.py 의 DecisionModel 과 v5/laya_adapter.py 의 단일 질문 입력 구조를 확인한 뒤 제안했다. 현재 forward 는 그룹별 여러 질문의 정규화를 제공하는 구현이 아니므로, 논문의 다중 그룹 인터페이스와 학습 마스크는 추가 개발 대상이다. 원래 실험 결과의 체크포인트를 확장 모델의 결과로 제시하지 않는다.

설계의 수치 가정: 최근 문맥 10 초, 장기 집계 300 초, 최대 32 사건, 총 4,096 토큰, 서비스 내부 예산 200ms 및 보조 학습 비율은 구현·검증을 시작하기 위한 후보값이다. 현재 실험으로 최적성이나 운영 보장을 입증한 값이 아니다.